




十分钟读懂Diffusion：图解Diffusion扩散模型

绝密伏击  
奇虎360 高级算法专家

439 人赞同了该文章

在之前的文章中，我们曾经介绍过Diffusion的具体原理，但是讲的还是比较偏理论，为了让大家快速了解Diffusion原理，这篇文章我们通过图解的方式。


绝密伏击：AIGC爆火的背后——扩散模型
DDPM浅析
139 赞同 · 14 评论 文章



1. Diffusion文字生成图片——整体结构


1.1 整个生成过程

我们知道在使用 Diffusion 的时候，是通过文字生成图片，但是上一篇文章中讲的Diffusion模型输入只有随机高斯噪声和time step。那么文字是怎么转换成Diffusion的输入的呢？加入文字后Diffusion 又有哪些改变？下图可以找到答案。




文字生成图片全过程

实际上 Diffusion 是使用Text Encoder生成文字对应的embedding（Text Encoder使用CLIP模型），然后和随机噪声embedding，time step embedding一起作为Diffusion的输入，最后生成理想的图片。我们看一下完整的图：



token embedding、随机噪声embedding、time embedding一起输入diffusion

上图我们看到了Diffusion的输入为token embedding和随机embedding，time embedding没有画出来。中间的Image Information Creator是由多个UNet模型组成，更详细的图如下：




更详细结构

可以看到中间的Image Information Creator是由多个UNet组合而成的，关于UNet的结构我们放在后面来讲。

现在我们了解了加入文字embedding后 Diffusion 的结构，那么文字的embedding是如何生成的？接下来我们介绍下如何使用CLIP模型生成文字embedding。


1.2 使用CLIP模型生成输入文字embedding

CLIP 在图像及其描述的数据集上进行训练。想象一个看起来像这样的数据集，包含4 亿张图片及其说明：




图像及其文字说明


实际上CLIP是根据从网络上抓取的图像及其文字说明进行训练的。CLIP 是图像编码器和文本编码器，图像和文本编码器对它们



然后使用余弦相似度刻画是否匹配。最开始训练时，相似度会很低。




然后计算loss，更新模型参数，得到新的图片embedding和文字embedding




通过在训练集上训练模型，最终得到文字的embedding和图片的embedding。有关CLIP模型的细节，可以参考对应的论文。

1.3 UNet网络中如何使用文字embedding

前面已经介绍了如何生成输入文字embedding，那么UNet网络又是如何使用的？实际上是在UNet的每个ResNet之间添加一个Attention，而Attention一端的输入便是文字embedding。如下图所示。






2. 扩散模型Diffusion

前面介绍了Diffusion是如何根据输入文字生成图片的，让大家有个大概的了解，接下来会详细介绍扩散模型Diffusion是如何训练的，又是如何生成图片的。


2.1 扩散模型Diffusion的训练过程



Diffusion模型的训练可以分为两个部分：


- 1. 前向扩散过程 (Forward Diffusion Process) → 图片中添加噪声
- 2. 反向扩散过程 (Reverse Diffusion Process) → 去除图片中的噪声

2.2 前向扩散过程




前向扩散过程是不断往输入图片中添加高斯噪声。

2.3 反向扩散过程



反向扩散过程是将噪声不断还原为原始图片。

2.4 训练过程



在每一轮的训练过程中，包含以下内容：

1. 每一个训练样本选择一个随机时间步长 t
2. 将time step t 对应的高斯噪声应用到图片中
3. 将time step转化为对应embedding

下面是每一轮详细的训练过程：

收起

ion文字生成图片——...

↑生成过程

用CLIP模型生成输入文...

let网络中如何使用文...

型Diffusion

放模型Duffison的训练...

与扩散过程

与扩散过程

统过程


斯噪声中生成原始图...

JNet模型结构


Diffusion模型的缺点及...

JNet网络同时输入文...

1. Randomly select a time step & encode it



2. Add noise to image




$$\varepsilon \sim \mathcal{N}(0, 1)$$

$$\alpha_t = 1 - \beta_t$$

$$\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$


Adjust the amount of noise according to the time step t

3. Train the UNet



知乎 @绝密伏击


2.5 从高斯噪声中生成原始图片（反向扩散过程）



上图的Sample a Gaussian表示生成随机高斯噪声，Iteratively denoise the image表示反向扩散过程，如何一步步从高斯噪声变成输出图片。可以看到最终生成的Denoised image非常清晰。

补充1：UNet模型结构

前面已经介绍了Diffusion的整个过程，这里补充以下UNet的模型结构，如下图所示



网络。

前面我们在介绍整个**文字生成图片**的架构中，图里面用的都是**Stable Diffusion**，后面介绍又主要介绍的是Diffusion。其实Stable Diffusion是Diffusion的改进版。

Diffusion的**缺点**是在反向扩散过程中需要把完整尺寸的图片输入到U-Net，这使得当图片尺寸以及time step t 足够大时，Diffusion会非常的慢。Stable Diffusion就是为了解决这一问题而提出的。后面有时间再介绍下Stable Diffusion是如何改进的。

补充3：UNet网络同时输入文字embedding

在第2节介绍Diffusion原理的时候，为了方便，都是没有把输入文字embedding加进来，只用了time embedding和随机高斯噪声，怎么把文字embedding也加进来可以参考前面的1.3节。

补充4：DDPM为什么要引入时间步长 t

引入时间步长 t 是为了模拟一个随时间逐渐增强的扰动过程。每个时间步长 t 代表一个扰动过程，从初始状态开始，通过多次应用噪声来逐渐改变图像的分布。因此，较小的 t 代表较弱的噪声扰动，而较大的 t 代表更强的噪声扰动。

这里还有一个原因，DDPM 中的 UNet 都是共享参数的，那如何根据不同的输入生成不同的输出，最后从一个完全的一个随机噪声变成一个有意义的图片，这还是一个非常难的问题。我们希望这个 UNet 模型在刚开始的反向过程之中，它可以先生成一些物体的大体轮廓，随着扩散模型一点一点往前走，然后到最后快生成逼真图像的时候，这时候希望它学习到高频的一些特征信息。由于 UNet 都是共享参数，这时候就需要 time embedding 去提醒这个模型，我们现在走到哪一步了，现在输出是想要粗糙一点的，还是细致一点的。

所以加入时间步长 t 对生成和采样过程都有帮助。

补充5：为什么训练过程中每一次引入的是随机时间步长 t

我们知道模型在训练过程中 loss 会逐渐降低，越到后面 loss 的变化幅度越小。如果时间步长 t 是递增的，那么必然会使得模型过多的关注较早的时间步长（因为早期 loss 大），而忽略了较晚的时间步长信息。

参考

medium.com/@steinsfu/st...

jalammar.github.io/illu...

pub.towardsai.net/getti...

zhuanlan.zhihu.com/p/59...

zhuanlan.zhihu.com/p/59...

arxiv.org/abs/2103.0002...

最近将专栏相关内容收录在我的新书「**推荐系统技术原理与实践**」中，这本书系统性地整理、介绍了专栏中所有的重点内容，欢迎订阅，谢谢知友们的支持！

《推荐系统技术原理与实践（异步图书出品）》(文亮)【摘要 书评 试读】- 京东图书
item.jd.com/14048272.html





¥71.00

价格具有时效性

推荐系统技术原理与实践 (异步图书出品)



长按或扫描查看

知乎 @绝密伏击

编辑于 2023-07-03 15:14 · IP 属地北京

模型 AIGC 扩散模型

写下你的评论...

39 条评论

默认 最新



涤烦子

写得真到，但是有个小问题想请教一下：
add noise to image是直接一步到位，从x0变成了xt，此时只有一个噪声图像。
train the unet的时候，UNET每次只预测x(t-1)到xt的噪声图像，从xt到x0有t张噪声图像。
那这两种噪声图像数量不一致，意义也不一致，怎么对比计算loss呢？还是说我理解有误，不是这两种噪声图像计算loss？


02-22 · IP 属地广东

回复 3



绝密伏击 作者

add noise to image的确是直接一步到位，但是当中的高斯噪声 $\epsilon \sim N(0,1)$ ，是Unet的label，也就是每一步计算xt的时候，都有一个 $\epsilon \sim N(0,1)$ 作为Unet的label，你可以仔细看下下面这张图中xt最后一项 $\epsilon \sim N(0,1)$



02-22 · IP 属地北京

回复 1



绝密伏击 作者

另外可以看下完整的训练过程，描述的更清晰

Algorithm 1 Training

```
1: repeat
2:    $x_0 \sim q(x_0)$ 
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$ 
4:    $\epsilon \sim N(0, I)$ 
5:   Take gradient descent step on
      $\mathbb{E} \|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2$ 
6: until converged
```

回复 1

- 02-01 · IP 属地中国澳门

绝密伏击 作者

主要是因为这种方法可以帮助模型在训练过程中避免陷入局部最优解，并且有助于提高模型的鲁棒性。

使用固定步长的训练方法容易陷入局部最优解，因为这种方法会使模型只关注特定的变化模式，而忽略其他可能的模式。而随机步长的方法可以使模型在训练过程中跳出局部最优。

如果训练过程中，每次都按t从1到N输入，这样unet模型来讲，反而去拟合t

04-02 · IP 属地北京

回复 4
- 就不打野 · 绝密伏击

欸，确实是这样，只第五条我看了半天没卡懂，然后就来翻评论，看到这个才看懂了

05-04 · IP 属地上海

回复 赞
- 凉饭

我英语不及格，看完没看懂啊，那位大佬可以用通俗易懂得中文或者方言给我解释下

05-12 · IP 属地云南

回复 2
- 干鱿鱼好吃嘛

想请教一下博主，1.3节配图中的noise amount具体指的是什么呢？

02-28 · IP 属地黑龙江

回复 2
- 送信的猫球

每个字都看了，什么也没记住

05-20 · IP 属地江苏

回复 1
- 呦呦鹿鸣

文章写的非常好，是我看过diffusion model最清晰的了

06-21 · IP 属地浙江

回复 1
- 绝密伏击 作者

感谢

06-21 · IP 属地北京

回复 赞
- 三硝基甲苯

写得真好

07-08 · IP 属地北京

回复 赞
- 速冻香蕉

Image Information Creator中需要经过个Unet step而不是有多个Unet。。

07-07 · IP 属地四川

回复 赞
- muaddib

👍，不过这篇文章的数学推导感觉更系统： [一文讲透AI绘画的Diffusion技术原理：从数学到编程](#) 可以搭配着一起看

06-07 · IP 属地北京

回复 赞
- 啦啦啦

去噪过程需要优化吗

06-01 · IP 属地北京

回复 赞
- 永哥

配合b站deep thoughts食用更佳

05-11 · IP 属地四川

回复 赞
- 永哥

deep thoughts视频

05-11 · IP 属地四川

回复 赞
- Fatemin

大佬请教一下，CLIP和diffusion其实是两个技术栈吗，还是说diffusion是对clip的一种运用

05-03 · IP 属地上海

回复 赞

x0, 再推导出 $\mu(x_t, x_0)$, 再推出来 x_{t-1} 🤖刚学, 看不太懂那些推导公式
04-21 · IP 属地中国香港

回复 赞

 **阿闭** · 绝密伏击
好的, 谢谢楼主 🙏
04-22 · IP 属地中国香港

回复 赞

 **绝密伏击** 作者 🏆
因为无论是前向过程还是反向过程都是一个参数化的马尔可夫链, 所以会满足相应的数学推导。
04-21 · IP 属地北京

回复 赞

展开其他 2 条回复 >

 **最佳观众**
文章非常棒, 有一个疑问想请教, 在文中 “2.5 从高斯噪声中生成原始图片 (反向扩散过程)”, 当 $t=1000$ 和 $t=2$ 时, 在去噪的时候公式里都加上最后一项 “根号下 $\beta t \epsilon$ ”, 但是在 $t=1$ 时就没有这一项了, 还有加这一项的意义是什么, 不是说去噪么, 怎么还把噪声又加回来了。
04-02 · IP 属地江苏

回复 赞

 **够钟** · 最佳观众
 $t > 1$ 的时候增加噪声是为了增加随机性, $t=1$ 的时候就是最后一步即输出 x_0 的时候了, 所以不需要加了。
07-06 · IP 属地重庆

回复 赞

 **最佳观众** · 绝密伏击
推导中貌似没提到这个。。。感觉加噪声这一步应该是实践出来的经验, 这么做效果就是好, 不加就不行
04-17 · IP 属地江苏

回复 赞

展开其他 1 条回复 >

 **nono**
写的好好, 谢谢。稍微提一下文章里的diffusion都写成了Duffision
03-29 · IP 属地山西

回复 赞

 **哈哈大白猫Sherry** · 绝密伏击
2.1的duffusion还没改回来哦 😊
05-09 · IP 属地中国香港

回复 赞

 **绝密伏击** 作者 🏆
确实是 😊, 感谢指正
04-02 · IP 属地北京

回复 赞

 **努力学习的AQ**
非常棒
03-24 · IP 属地北京

回复 赞

 **谷下雨**
先收藏了, 以后再看 😊
02-25 · IP 属地北京

回复 赞

 **绝密伏击** 作者 🏆
👍
02-27 · IP 属地北京

回复 赞

 **达不溜王**
UNet的训练不需要text embedding的参与?
02-16 · IP 属地北京

回复 赞

 **nikoniko** · 达不溜王
stable diffusion 用的cross attention map 计算text和noisy image 的关系
04-25 · IP 属地浙江

回复 赞

02-18 · IP 属地北京

回复 赞

展开其他 1 条回复 >

大魔王

不错，赞👍👍

写下你的评论...

- Deep Learning

02-18 · IP 属地北京

深度学习的应用实践
- 深度学习应用

分享一些深度学习的应用
- CV

计算机视觉论文速递

欢迎关注微信公众号：CVer
- AIGC


AIGC前沿应用

介绍AIGC的技术原理和前沿应用

推荐阅读

**Python机器学习
全流程项目实战精讲**
鱼伟 (louiswill)，机器学习工程师

深度学习第46讲：seq2seq模型
程序员必修... 发表于程序猿数据...



Diffusion Models - 扩散模型 (一)
Redfl... 发表于Deep ...



**模型汇
Attention**
深度学...